

INFORME DE AUDITORÍA ACADÉMICA

Tercera instancia · Verificación de correcciones y auditoría del repositorio, previa a la defensa

Trabajo auditado	Automatización del ciclo post-venta en e-commerce: pipeline de procesamiento de órdenes y atención al cliente con IA, implementado con n8n
Autores	Santiago Sordi — Ignacio Odorico — Juan Cruz Ana
Director	Alberto Cortez
Carrera	Tecnicatura Universitaria en Programación — UTN Facultad Regional Mendoza
Archivo cotejado	TRABAJO_FINAL_UTN_v6-c2.pdf · 138 páginas · tamaño carta
Repositorio cotejado	github.com/IgnacioOdorico/Automatizacion-de-Atencion-al-Cliente-en-E-commerce-e-Inteligencia-Artificial · etiqueta entrega-2026-09-r4 (commit b64099b , 17/09/2026)
Instancia anterior	Trabajo_Final_UTN.pdf · 100 páginas · 16 hallazgos · 8,2 / 10
Composición	9 capítulos · 12 anexos (A a L) · 11 figuras sobre 11 imágenes distintas · 26 tablas numeradas en el cuerpo y 3 en anexos
Norma de referencia	APA 7. ^a edición · Modalidad: tribunal evaluador simulado

0. Alcance y método de esta instancia

La versión entregada no es una corrección puntual de la anterior: pasó de cien a ciento treinta y ocho páginas, incorporó un diseño factorial sobre el prompt del clasificador (E8), una evaluación del contenido de las respuestas por jueces y por verificación automática (E6), los Anexos K y L, y reescribió buena parte de los Capítulos 2, 3 y 5. Por eso esta auditoría tiene tres objetos: verificar el estado de los dieciséis hallazgos de la instancia anterior, auditar la versión como documento nuevo y —por primera vez— auditar el repositorio público que el trabajo invoca como respaldo de cada cifra.

Esa tercera verificación cambia el alcance de lo que el tribunal puede afirmar. En las instancias anteriores se recalcularon las cifras a partir de lo que el documento transcribía; en esta se recalcularon a partir de los archivos crudos versionados (corpus, etiquetas, clasificaciones, recuentos por mensaje del diseño factorial, resultados de E1, E6 y de las pruebas funcionales), se leyeron las consultas SQL y el código de los nodos de los workflows exportados, las definiciones de los tableros de Grafana y el historial de commits, y se cotejaron las afirmaciones del documento contra el registro de trabajo del propio equipo (docs/PLAN_REGENERACION_EVIDENCIA.md y los README de cada experimento). Se verificaron además contra fuente las referencias incorporadas en esta versión de publicación más reciente.

Se mantienen el criterio de que una afirmación no verificable no se computa como error y la clasificación en cuatro severidades: **crítico** compromete la aprobación y no es subsanable durante la defensa; **alto** genera observación mayor; **medio**, observación menor; **bajo**, mejora formal.

1. Resumen ejecutivo

Dictamen: aprobado — apto para la defensa, con tres observaciones mayores que deben subsanarse en el documento antes de la entrega definitiva.

Puntaje global: **8,2 / 10** · instancia anterior: 8,2 / 10 · primera instancia: 4,2 / 10

El puntaje coincide con el de la instancia anterior, y conviene explicar por qué no debe leerse como estancamiento. El trabajo mejoró en sustancia más de lo que mejoró entre la primera y la segunda instancia: reemplazó una ablación con factores confundidos por un diseño factorial fijado antes de medir, verificado ejecución por ejecución con la huella del prompt, y cuyo resultado desmiente la conclusión que el propio equipo había publicado; reportó como fallido el instrumento de evaluación de contenido en lugar de extraer de él una proporción; reclasificó como no aprobadas dos pruebas funcionales que antes figuraban aprobadas sin evidencia; y reunió en el Anexo L un registro de desvíos que un tribunal rara vez recibe. Lo que cambió al mismo tiempo es la profundidad de la auditoría: al leer el repositorio aparecieron tres cuestiones que el documento no declara y que el equipo conocía —una corrida del corpus descartada con treinta y cinco mensajes perdidos en silencio, consultas SQL construidas por interpolación de texto del usuario, y una explicación del tablero del Flujo 1 que las vistas efectivamente aplicadas contradicen—. Ninguna de las tres exige volver a medir; las tres exigen escribir.

La reproducibilidad es, otra vez, la virtud central, y ahora está verificada contra los datos crudos y no solo contra lo transcripto. La matriz de confusión de la Tabla 5.8 y el TMR por intención de la Tabla 5.5 se reproducen exactamente desde `e2_corrida2_clasificaciones.csv` (media 1,469 s, desvío 0,246 s). El κ de 0,919 se reproduce desde las etiquetas del evaluador externo (47 de 50), con los mismos tres desacuerdos que describe la Sección 5.2.3. Los intervalos de Wilson de la Tabla 5.10 (140, 141, 118 y 111 sobre 150) y el de 2 sobre 18 del Anexo K coinciden en el decimal; el McNemar exacto de C3 frente a C4 da $p = 0,265$ y, con Holm, 0,530; la exactitud media por repetición y su intervalo coinciden para C1 y C2 al recalcularlos desde `e8_aciertos_por_mensaje.csv`. La similitud entre el ejemplo de Córdoba y el mensaje más parecido del corpus da 0,885 con el procedimiento declarado. Los descriptivos del baseline, su intervalo, la correlación de $-0,693$, la U de Mann-Whitney y la t de Welch siguen reproduciendo. Las cifras de E1 coinciden con el archivo de métricas de la corrida. No encontré una cifra estadística que no se derive de los datos versionados.

Rectificaciones del tribunal. La lectura del repositorio muestra que la auditoría de segunda instancia contiene tres afirmaciones erróneas, y corresponde decirlo antes de reprochar nada:

- Destacó como autocrítica ejemplar que «el nodo que arma el contexto de preguntas frecuentes existe pero su salida nunca llega al prompt» y que, por eso, el 92,7 % era «un piso y no un techo». La afirmación era falsa: provenía de auditar una versión del workflow distinta de la que corrió el 12/08, como documenta el Anexo L. El tribunal la validó sin verificarla contra el historial.
- Afirmó que la prueba de concurrencia «confirmó la atomicidad». No la confirmó: la ausencia de sobreventa se debe a la restricción `CHECK (stock >= 0)` y no a que el flujo sea atómico, como ahora explica correctamente la Sección 5.1.3.
- Propuso, en su hallazgo A-02, que el primer punto de la serie diaria de la Figura 7 correspondía a órdenes de carga inicial. El equipo adoptó esa lectura en el epígrafe, y el repositorio la refuta (hallazgo A-01 de esta instancia).

El equipo corrigió por su cuenta los dos primeros errores, lo cual dice mucho a su favor. El tercero se originó en este tribunal y se corrige aquí.

Las referencias incorporadas en esta versión son reales y se les atribuye lo que sostienen. Verifiqué contra fuente, entre otras, el preprint de Amir y Atif (2026) —veinte ejecuciones manuales frente a veinticinco automatizadas, de 185,35 s a 1,23 s, unas 151 veces—, el de Tang et al. (2026) sobre más de seis mil flujos de n8n con mecanismos explícitos de confiabilidad poco comunes, y el artículo de Larsen et al. (2026), con su encuesta a 274 potenciales usuarios. Todas las entradas de la lista están citadas y todas las citas tienen entrada; la cursiva de revistas y actas quedó normalizada, con un residuo en el formato de los preprints.

Distribución de hallazgos

Severidad	1. ^a inst.	2. ^a inst.	3. ^a inst.	Naturaleza dominante de lo que resta
Crítico	9	0	0	—
Alto	12	2	3	Un tablero cuya explicación contradicen las vistas efectivamente aplicadas; una corrida del corpus con pérdida silenciosa que el documento no declara; consultas SQL por interpolación de texto del usuario, conocidas por el equipo y no declaradas
Medio	10	6	8	Un oráculo de prueba que contradice el etiquetado propio, el artefacto medido distinto del descripto, un fallback silencioso a GENERAL, el alcance del TMR en Telegram, un reintento no mencionado y afirmaciones de menor alcance que los datos
Bajo	8	8	9	Formato de preprints, intervalos y controles que no se informan aunque existen, residuos de nomenclatura y de evidencia
TOTAL	39	16	20	

2. Verificación de los hallazgos de la instancia anterior

«Cerrado» significa que el defecto no está presente en el archivo entregado.

ID	Estado	Verificación
A-01	Cerrado	La Tabla 3.5 consigna para PC-04 «Ticket creado + is_urgent=true + respuesta al cliente por el canal de origen», sin notificación al administrador. La prueba se ejecutó el 17/09 con evidencia: intención RECLAMO, marca de urgencia y ticket 635 de prioridad urgent (experiments/PF).
A-02	No cerrado	La §4.5 se reescribió declarando qué paneles filtran por procedencia, pero la nueva explicación es incompatible con el valor que muestra la Figura 7 y con las vistas que estaban aplicadas al capturarla. Se reformula como A-01 de esta instancia.
M-01	Cerrado	«Disponibilidad continua» desapareció del resumen, del abstract y de la §5.4; la §6.1 la declara propiedad esperable de la arquitectura y no medida.
M-02	Cerrado	La §4.2.1 y la celda de OE3 declaran que order_items existe en el esquema y que el pipeline carga órdenes mono-producto.
M-03	Cerrado	El diseño de las pruebas pasó a las Tablas 3.4 y 3.5 y los resultados a las §§5.1.1 y 5.2.1, con evidencia versionada. Subsiste un problema distinto en PC-05, que se consigna como M-01 de esta instancia.
M-04	Cerrado	La §5.2.2 presenta la diferencia entre canales como observación, enumera cuatro factores de confusión y descarta el prompt como el menor, con el dato del diseño factorial (1,55 s y 1,57 s para prompts de 1154 y 6338 caracteres).
M-05	Cerrado	El epígrafe de la Figura 9 explica por qué el panel de canales muestra solo el canal simulado y por qué la serie de correo está en cero.
M-06	Cerrado	La §5.5 (f) consigna la ventana de una hora y su costo sobre la lectura del desvío.
B-01	Cerrado	Los listados de figuras del frontispicio y del Anexo F están completos.
B-02	Cerrado	El listado de tablas repite solo la fila de encabezado en la segunda página.
B-03	Cerrado	El Anexo G ya no usa los rótulos «A1 y A2».
B-04	Cerrado	Los comentarios del DDL describen el propósito técnico de cada objeto.
B-05	Parcial	Verificado por fuente tipográfica en las páginas 104 a 110: revistas, volúmenes y actas llevan cursiva de manera uniforme. Los preprints conservan tres formatos distintos (B-01 de esta instancia).
B-06	Cerrado	La celda de OE1 ya no afirma una degradación de diez veces, y la Tabla 5.3 agrega el MTTR bajo concurrencia (0,100 s, derivado, con la aclaración de que su desvío no es derivable).
B-07	Cerrado	El epígrafe de la Figura 8 identifica la corrida de verificación de cinco órdenes y aclara que no integra el total de la Tabla 5.3.
B-08	Cerrado	La §3.2 describe «20 productos de tecnología y mobiliario», y la Tabla 4.7 explica el rótulo «(Producción)» del nodo 17.

3. Fortalezas de esta versión

- **Un diseño factorial que refuta una conclusión propia.** E8 cruza la base de conocimiento con el bloque de reglas y ejemplos en cuatro condiciones, tres repeticiones y 1800 clasificaciones. El diseño, los contrastes y la regla de decisión se versionaron antes de medir (commit 628b260). Cada bloque verifica antes de enviar que el prompt activo sea el de su condición y exporta después la huella del prompt con que corrió cada ejecución. El resultado — 17,3 puntos para las reglas y los ejemplos, 2,0 para la base y ninguno cuando las reglas están presentes— contradice lo que la versión anterior afirmaba, y el trabajo lo dice en el cuerpo y lo registra en el Anexo L.

- **Momento de fijación de cada criterio.** La Tabla 5.11 agrega una columna que indica cuándo se fijó cada criterio, con el commit que lo acredita, y la §5.3 distingue entre «se sostiene frente a un criterio» y «confirmación». Declarar que el umbral de 10× de H1 y la extensión de H2a a las cuatro categorías se fijaron con el resultado conocido es exactamente lo que la honestidad exige y casi nadie hace.
- **Un instrumento fallido reportado como tal.** La evaluación por jueces no alcanzó un acuerdo suficiente (κ de 0,167 y 0,358; 0,318 intra-evaluador). El trabajo no extrae de ella ninguna proporción, aplica a los jueces el mismo control de tiempos que al etiquetado —y excluye tres corridas por él—, y diagnostica la causa en la estructura de la rúbrica, cuyos niveles no son excluyentes. La §7.2 convierte ese diagnóstico en un instrumento alternativo concreto.
- **Una verificación automática aplicada también al propio prompt.** El guion que contrasta los datos concretos contra la base se aplicó a los ejemplos del prompt y encontró que uno de ellos enseña al modelo un plazo que la base no contiene. El trabajo lo declara como defecto del artefacto medido y lo conserva en la transcripción.
- **La identidad del asistente, medida.** La §2.5 no se limita a señalar que la regla crítica 3 contraviene el deber de informar el carácter automatizado del canal: consulta las respuestas efectivamente registradas y encuentra que, en la corrida medida, el sistema afirmó ser una persona. El vínculo con el caso *Moffatt v. Air Canada* es pertinente y está bien acotado.
- **Pruebas funcionales con evidencia, aunque perjudique.** PF-04 y PF-05 se reclasificaron como no aprobada y parcial tras reejecutarlas con evidencia, y el trabajo identifica el patrón común con la prueba de concurrencia: el webhook responde HTTP 200 sin cuerpo cuando la orden no se procesa.
- **Mecanismo correcto de la ausencia de sobreventa.** La §5.1.3 explica que la lectura y el descuento del stock son sentencias separadas sin bloqueo, que lo que impide la sobreventa es la restricción del esquema, y que las latencias bajo concurrencia tienen sesgo de supervivencia. Las tres precisiones son correctas y corrigen lo que este tribunal había dado por bueno.
- **Un registro de desvíos como anexo.** El Anexo L reconstruye qué versión del workflow corrió en cada medición, a partir del historial del motor de flujos, e identifica el commit que se había citado por error. Es la práctica que el hallazgo A-02 de esta instancia pide extender.

4. Hallazgos de severidad alta

A-01 — La Figura 7 no muestra lo que la §4.5 y su epígrafe dicen que muestra

La §4.5 declara ahora que los paneles «Órdenes totales» y «Órdenes procesadas por día» consumen `v_metrics_summary` y `v_daily_order_summary`, que según el Anexo A agregan sobre la totalidad de la tabla de órdenes, y el epígrafe de la Figura 7 concluye que «el primer punto de la serie diaria corresponde a las órdenes de carga inicial». Las definiciones de los tableros versionadas en `grafana/dashboards/tesis-flujo1.json` confirman qué vista consume cada panel. Pero la explicación no se sostiene por cuatro razones verificables.

- **El valor del panel es incompatible con la vista del Anexo A.** El panel muestra 173 órdenes. Con la definición publicada, la vista contaría también las 12 órdenes del baseline manual (`e4_manual`) y las filas de carga inicial (`synthetic`), que según el propio registro del equipo seguían en la base; el total sería necesariamente mayor que el de registros medidos.

- **Las vistas aplicadas al capturar eran otras.** `experiments/E5/vistas_measured.sql` redefinió las vistas agregando `WHERE data_source = 'measured'`, y su cabecera indica aplicarlo «sobre la BD viva que se va a capturar». Las figuras se recapturaron con esas vistas (commit `9d4fe1c`, 19/08). El panel de 173 es, por lo tanto, el recuento de órdenes medidas en esa fecha, y el Anexo A no transcribe las vistas que produjeron la figura.
- **El «primer punto» no existe como dato.** La serie no tiene un punto el 28/07. La línea entra por el borde izquierdo desde un punto anterior, fuera del rango visible. La lectura compatible con el repositorio es la siguiente: las dos órdenes de demostración de principios de julio (medidas, según la Tabla 5.3) y las 171 del 10/08 suman 173, y la interpolación lineal entre ambos puntos pasa por unas 115 órdenes a la altura del 28/07, que es lo que se ve. Esta es la hipótesis que el tribunal debió formular en la instancia anterior.
- **La figura y la tabla ya no coinciden.** La Tabla 5.3 declara 174 órdenes medidas porque incorpora ORD-AUDIT-ALERT, generada con la implementación de la alerta de stock bajo (commit `fdc9950`, 26/08), posterior a la captura. La Figura 7 muestra 173 en el total y 66 confirmadas en la torta. Es una diferencia de una unidad, pero es exactamente el tipo de discordancia entre figura y tabla que motivó la primera instancia.

Corrección. Transcribir en el Anexo A las vistas efectivamente aplicadas —o declarar que `vistas_measured.sql` las reemplazó sobre la base capturada—; reescribir la §4.5 y el epígrafe de la Figura 7 con la explicación correcta de la serie; y declarar la fecha de captura y la diferencia entre 173 y 174, o recapturar el tablero. La recomendación de la §7.2 de homogeneizar el filtro en las vistas ya está implementada en ese archivo: basta con incorporarla al esquema versionado.

A-02 — Una corrida del corpus con treinta y cinco mensajes perdidos en silencio no figura en el documento

El 12/08 a las 11:09 el corpus se ejecutó por primera vez contra el Flujo 2. Las 150 solicitudes recibieron HTTP 200, pero solo quedaron 115 filas en `interactions`: faltaron las 35 que el modelo había enviado a la rama ESTADO_PEDIDO (`experiments/E2/resultados/e2_faltantes_2026-08-12_11-09-23.csv`). El registro del equipo (`docs/PLAN_REGENERACION_EVIDENCIA.md`, §14.7) documenta el mecanismo, identificado como defecto D-7: cuando el pedido citado no existe, Buscar Pedido no emite ningún ítem, el resto del subgrafo no se ejecuta, el cliente no recibe respuesta y la ejecución queda en estado *success*. Se corrigió reescribiendo la consulta, y la corrida que el trabajo reporta se ejecutó a las 20:45 sobre el sistema corregido, con una versión del workflow publicada cuatro minutos antes, dato que el Anexo L sí consigna.

Lo que el documento no consigna es la existencia de esa primera corrida ni lo que mostró. Su exactitud, recuperada de los registros de ejecución, fue de 140/150 (`e2_clasificaciones.csv`), las etiquetas coincidieron con las de la corrida definitiva en 145 de 150 mensajes, y el propio registro del equipo advierte que el TMR por clase fue cerca de un 40 % mayor que en la corrida definitiva —y que reportar un TMR único sin esa varianza «es frágil ante el tribunal»—.

Por qué pesa. No hay aquí selección favorable: la corrida omitida tuvo una exactitud algo mayor. El problema es de transparencia y de alcance. Es la falla silenciosa más grave observada en el Flujo 2 —el 23 % de los mensajes perdidos con la ejecución marcada como exitosa—, mayor que las dos que el trabajo sí enumera en las §§5.5 (h) y 6.3. Además, el Anexo L se presenta como la historia de las revisiones y la omite. Y la diferencia de TMR entre corridas del mismo día es precisamente la evidencia que la §5.5 (f) dice no tener.

Corrección. Declarar la corrida y el defecto en la §5.2.3 y en el Anexo L; incorporar D-7 a la §5.5 (h), a la §6.3 y a la limitación (ix) de la §6.4; y consignar en la §5.5 (f) la variación de TMR observada entre ambas corridas, con la salvedad de que la primera no escribió las 35 interacciones faltantes.

A-03 — Las consultas SQL se construyen interpolando texto del usuario, y el documento no lo declara

Los nodos de base de datos de ambos flujos arman sus sentencias insertando valores recibidos directamente en el texto de la consulta, sin parámetros. Tres casos, tomados de los workflows exportados:

```
Registrar Orden:
  SELECT '{{ $json.body.order_number }}', '{{ $json.body.customer_name }}', ...
        '{{ $json.body.quantity }}', ...
  WHERE p.sku = '{{ $json.body.product_sku }}'
Crear Ticket:
  VALUES ('{{ $json.canal }}', '{{ $json.user }}', '{{ $json.message }}', ...
Buscar Pedido:
  FROM (SELECT '{{ $json.order_id }}'::varchar AS oid) q LEFT JOIN orders ...
```

Hay dos consecuencias, una de seguridad y otra de robustez. La primera es que un valor diseñado para cerrar la comilla altera la sentencia: en `Registrar Orden` ese valor llega del cuerpo del webhook, que no tiene autenticación, y en `Buscar Pedido` llega del mensaje del cliente a través del modelo, que es un canal que el propio trabajo reconoce expuesto a inyección de instrucciones. La segunda es que un texto legítimo que contenga un apóstrofo rompe la sentencia. `Crear Ticket` no escapa el mensaje — `Registrar Interacción` sí lo hace—, de modo que, según la lectura del flujo, un reclamo escrito en inglés con una contracción detendría la ejecución antes del envío: el cliente no recibiría respuesta y no quedaría registro, que es otra instancia de la pérdida silenciosa que el trabajo documenta. Lo mismo ocurriría con un cliente de apellido O'Brien en `Registrar Orden`.

El equipo lo sabía. El registro de trabajo lo consigna como defecto D-9, de severidad alta, con la indicación «corresponde arreglarlo y declararlo»; la corrección de D-7 conservó la interpolación. El documento trata la inyección de instrucciones en la §5.5 y recomienda autenticación de webhooks en la §7.1, pero no menciona la inyección SQL.

Corrección. Declararlo en la §5.5 y en la §6.4 como defecto del artefacto medido, y agregar a la §7.1 la parametrización de las consultas (los nodos de PostgreSQL de n8n admiten parámetros de consulta). Si se corrige el workflow antes de la entrega, conviene declarar que el artefacto publicado difiere del medido solo en ese punto y agregar una prueba funcional con un mensaje que contenga un apóstrofo.

5. Hallazgos de severidad media

ID	Ubicación	Hallazgo
M-01	Tabla 3.5, §5.2.1, Tabla 6.1	El resultado esperado de PC-05 contradice el etiquetado del propio equipo. PC-05 espera GENERAL para «¿Tienen tiendas físicas?» y se informa como no aprobada porque el sistema clasificó FAQ. Pero el mensaje 44 del corpus, «tienen local físico para retirar?», tiene como etiqueta de referencia FAQ. La definición de FAQ que recibió el evaluador independiente es «pregunta general sobre la tienda». Y la base de conocimiento contiene una entrada sobre retiro en local físico. El README de <code>experiments/PF</code> lo advierte, pero el documento no. Lo que falla es el oráculo de la prueba, no el sistema. No corresponde reescribir el criterio después de ver el resultado; corresponde mantener la prueba como no aprobada y declarar en la §5.2.1 y en la celda de OE5 que su resultado esperado es incoherente con la convención de etiquetado.
M-02	Cap. 4, Tabla 4.7, Figura 6	El Capítulo 4 describe un artefacto distinto del que produjo el 92,7 %. El corpus del 12/08 corrió sobre el workflow de catorce nodos (<code>commit f68da9d</code>). Ese workflow tiene un único disparador de webhook, no tiene disparador de Telegram ni de Gmail, ni <code>Router Canal</code> ni <code>Enviar Telegram</code> , y su nodo de salida es «Enviar Respuesta (Simulado)». La Tabla 4.7 y la Figura 6 describen el de dieciocho, sobre el que corrieron Telegram y E8. La diferencia se menciona en la §3.3 y en el Anexo L, pero el lector del Capítulo 4 no la encuentra. Basta una nota en la §4.4.1 que indique qué nodos no existían en la versión medida sobre el corpus.
M-03	§§4.4.1, 5.2.3	Los errores de parseo se registran como GENERAL. <code>Parse JSON</code> asigna GENERAL cuando la salida del modelo no contiene JSON válido o no trae el campo <code>intent</code> , y entrega al cliente «Disculpá, hubo un error». Ese caso se registra como clasificación y se computa como no escalada. El análisis de E8 informa cero errores de parseo por bloque, pero el documento no informa cuántos hubo en la corrida del corpus, pese a que el README de E2 lo fijaba como obligatorio. Tampoco lo menciona al interpretar los cuatro falsos positivos de GENERAL como efecto de «clase residual».
M-04	§§4.4.4, 5.2.2	El TMR también empieza en una marca escrita dentro del flujo. <code>received_at</code> la genera <code>Normalizar Mensaje</code> con <code>new Date()</code> , después del disparador, y <code>Registrar Interacción</code> la convierte con <code>::TIMESTAMP</code> —sin zona— en una columna con zona horaria. En consecuencia, el TMR de Telegram incluye el envío de la respuesta pero no el tramo de entrada desde Telegram hasta <code>n8n</code> , y la afirmación de que «su TMR incluye la latencia de red efectiva» debe acotarse al tramo de salida. Es la misma precisión que el trabajo ya hizo, con mérito, sobre el MTDD.
M-05	§§3.5.6, 5.2.4	El reintento del bloque C3-R3 no se menciona. El bloque 9 resultó inválido por una etiqueta fuera de vocabulario, se reintentó según la regla preregistrada (<code>C3_R3_i2</code>) y el reintento tuvo otra. Recién entonces se fijó el desvío que cuenta esas etiquetas como error y elige el primer intento utilizable, antes de los bloques 10 a 12 y sin haber visto exactitudes. El procedimiento es correcto y está declarado en el README, pero el documento afirma que «los doce bloques resultaron válidos» y que el modelo devolvió dos categorías inexistentes sin decir que la segunda apareció en un decimotercer bloque no primario. El análisis de sensibilidad con el reintento (79,3 % frente a 78,7 %) ya existe y debería citarse.

ID	Ubicación	Hallazgo
M-06	§§2.5, 7.1	El recuento sobre la identidad del asistente omite dos negaciones, y la recomendación omite su fuente. Ante «sos un bot o una persona?», la condición C1 —la configuración vigente— respondió en una repetición «No soy un bot genérico», y C3 respondió «No soy un bot, sino un asistente virtual». Ninguna encaja en las dos categorías que usa la §2.5. La primera frase reproduce casi literalmente el bloque IDENTIDAD («NO sos un chatbot genérico»), presente en las cuatro condiciones junto con «como si fuera una persona real», que dos respuestas de C4 también repiten. Eliminar la regla crítica 3, como recomienda la §7.1, no basta: hay que reescribir también el bloque de identidad.
M-07	Resumen, §§5.2.5, 5.5 (c), 6.4	La cifra de respuestas no respaldadas omite un caso que el propio trabajo identificó. La interacción 352 aplica a la confirmación de un pago el plazo de 24 horas hábiles que la base asigna al retiro de una devolución. El trabajo lo analiza como ejemplo del límite del procedimiento, pero el resumen y las conclusiones repiten «2 de 18». Corresponde decir en esos lugares que la regla automática encuentra 2 y que se conoce al menos un tercero fuera de su alcance (3 de 18 dan un intervalo de Wilson de 5,8 % a 39,2 %).
M-08	§3.5.2	El tamaño del corpus sí tuvo un cálculo previo. La §3.5.2 afirma que la suficiencia de la muestra «se estableció después de medir y no mediante un cálculo previo». El README de E2 registra que $n = 150$ se eligió porque cruzaba el umbral de significación de una prueba binomial contra 0,85, con $p \approx 0,043$, calculada con la exactitud no medida de la versión anterior. La razón real debe declararse, con su debilidad: el cálculo usó un valor que no provenía de una medición.

6. Hallazgos de severidad baja

ID	Ubicación	Hallazgo
B-01	Cap. 8	Los cinco preprints tienen tres formatos. Coucke et al. lleva el título en cursiva y el número de arXiv entre paréntesis, que es la forma APA 7. Amir y Atif, y Tang et al., llevan número pero no cursiva. Luo et al., y Perez y Ribeiro, llevan en cursiva la palabra «arXiv» y omiten el número. Conviene además indicar la versión consultada de Tang et al., que tiene una v2 de julio de 2026.
B-02	§5.2.4, Tabla 5.10	Se informa «el intervalo más amplio compatible con los recuentos», pero los aciertos por mensaje están versionados (<code>e8_aciertos_por_mensaje.csv</code>) y permiten el intervalo exacto. Recalculado: C1 [89,1; 97,2], C2 [90,5; 97,9], C3 [70,4; 83,0] y C4 [66,5; 80,2]. Conviene publicar el exacto y dejar el conservador como comprobación.
B-03	§3.5.3	El control test-retest se describe pero no se informa su resultado: 50 de 50 coincidencias, $\kappa = 1,000$, valor que el registro del equipo interpreta como recuerdo antes que como criterio. Por simetría con el control aplicado al evaluador externo, conviene informar también los tiempos del anotador del ground truth: mediana de 2,8 s y dos ítems por debajo de 1 s.
B-04	§5.1.1, Tabla 5.1	PF-01 a PF-03 no se reejecutaron y no tienen evidencia propia; su aprobación descansa en la corrida E1.a y en ORD-AUDIT-ALERT. El README de <code>experiments/PF</code> lo declara; el documento, no.
B-05	Metadatos, §7.1, Anexos G y H	El título en los metadatos del PDF todavía dice «atención al cliente omnicanal con IA». Los archivos de workflow conservan «Omnicanal» en el nombre, y el de producción no implementa identidad unificada. Conviene corregir los metadatos y aclarar en la §7.1 que el nombre del archivo no refleja la delimitación de la §2.3.1.
B-06	Anexo G, §7.1	El Anexo G describe la variante de producción del Flujo 1 con disparadores de WooCommerce y Shopify; la §7.1, con WooCommerce, Shopify y MercadoLibre.

ID	Ubicación	Hallazgo
B-07	§4.3.3, Tabla 4.5	Se indica qué nodo escribe <code>processed_at</code> en la rama con stock, pero no en la rama sin stock, donde el dato existe. El MTTD difiere por rama: 0,010 s frente a 0,006 s según el archivo de métricas de E1, porque la rama confirmada incluye el descuento y la evaluación de stock bajo. Conviene declararlo.
B-08	<code>experiments/</code> PF, Anexo L	Dos residuos de evidencia. El archivo resumen de PC-01 a PC-05 dice «ticket: (ninguno)» para PC-03 y PC-04, porque busca los tickets por <code>interaction_id</code> , que queda vacío; el archivo de detalle muestra los tickets 634 y 635. Y una corrida descartada de esas pruebas (03:41 UTC) terminó en error con HTTP 200 y dejó dos tickets sin respuesta; está declarada en el README, pero no en el Anexo L.
B-09	§5.2.5	La corrida válida de uno de los jueces es su tercera lectura de las mismas 45 respuestas, después de dos corridas invalidadas por tiempo. La exposición previa puede incidir en el acuerdo, y conviene consignarlo junto al k.

7. Calificación por capítulo

Se mantiene la rúbrica de seis dimensiones: rigor científico, calidad metodológica, redacción, calidad bibliográfica, cumplimiento APA y coherencia interna.

N.º	Capítulo	Antes	Ahora	Fundamento
1	Introducción	8,2	8,6	H1 se presenta como objetivo de estimación y cada hipótesis declara cuándo se fijó su criterio. La pregunta distingue qué admite comparación medida y qué no. Las ampliaciones de alcance se declaran como tales y no se computan como objetivos.
2	Marco Teórico	8,5	8,7	Incorpora con precisión la distinción entre inyección de contexto y RAG, la evaluación de texto generado, el no determinismo y el acuerdo entre evaluadores. La sección de marco legal gana con el análisis empírico de la identidad del asistente. En contra: el recuento de la §2.5 omite dos negaciones y no identifica el bloque de identidad como fuente.
3	Marco Metodológico	8,7	8,4	El diseño factorial y la evaluación de contenido están bien especificados, y la amenaza de independencia entre prompt y corpus se trata con cronología y similitud. En contra: la razón real del tamaño del corpus, el resultado del test-retest y los tiempos del anotador no se informan.
4	Desarrollo del Estudio	7,3	7,0	Se resolvieron <code>order_items</code> y la ubicación de las pruebas, y la descripción del prompt es ahora exacta. En contra: la explicación del tablero que las vistas aplicadas contradicen, las consultas por interpolación no declaradas, la versión de catorce nodos ausente del capítulo y el alcance del TMR.
5	Resultados y Análisis	8,2	7,8	El diseño factorial y la evaluación de contenido son lo mejor del trabajo en rigor, y todas las cifras reproducen desde los datos crudos. En contra: la corrida del corpus omitida, el oráculo de PC-05, el fallback a GENERAL no informado, el reintento de E8 no mencionado y el caso 352 fuera de la cifra principal.
6	Conclusiones	8,2	8,6	Las tres reservas a la conclusión sobre reglas y ejemplos —convención de desempate, sensibilidad al formato y alcance— son las que corresponden. La disponibilidad dejó de afirmarse y OE5 se declara cumplido en parte. En contra: la enumeración de fallas silenciosas y de limitaciones omite D-7 y D-9.

N.º	Capítulo	Antes	Ahora	Fundamento
7	Recomendaciones	8,8	8,5	Son concretas y se derivan de lo medido: descuento condicionado, validación de etiquetas, alineación de reglas, base y ejemplos, instrumento de contenido rediseñado y descomposición del factor R. En contra: faltan la parametrización de consultas y la revisión del bloque de identidad.
8	Referencias	8,0	8,4	La correspondencia con las citas es biunívoca, el orden alfabético se mantiene, las cursivas de revistas están normalizadas y las fuentes nuevas fueron verificadas. En contra: el formato despasejo de los preprints.
9	Anexos	8,3	8,2	El Anexo H (prompt íntegro con sus defectos), el K (verificación dato por dato) y el L (registro de desvíos) son evidencia auditable de primer nivel. En contra: el Anexo A no transcribe las vistas con que se capturaron las figuras, y el L omite la primera corrida del corpus y D-9.
10	Redacción y presentación	7,5	8,2	Los listados del frontispicio están corregidos y la prosa es precisa y sostiene bien las salvedades. En contra: los residuos de nomenclatura en los metadatos y en los nombres de archivo, y alguna densidad excesiva en el Capítulo 5.

Promedio global: 8,2 / 10.

8. Plan de corrección

Ninguna acción de este plan exige volver a medir. El Bloque 1 es condición para la entrega definitiva.

Bloque 1 — Antes de la defensa

- **Declarar la primera corrida del corpus y el defecto D-7** (A-02): §5.2.3, §5.5 (f) y (h), §6.3, §6.4 y Anexo L, con su exactitud, sus 35 pérdidas y la variación de TMR entre corridas.
- **Declarar la construcción de consultas por interpolación** (A-03): §5.5, §6.4 y §7.1; si se corrige el workflow, declarar la diferencia con el artefacto medido y agregar una prueba con apóstrofo.
- **Corregir la explicación del tablero del Flujo 1** (A-01): transcribir o citar las vistas aplicadas, reescribir la §4.5 y el epígrafe de la Figura 7, y declarar la fecha de captura y la diferencia 173/174, o recapturar.
- **Indicar en el Capítulo 4 que el corpus corrió sobre la versión de catorce nodos** y cuáles faltaban (M-02).
- **Declarar la incoherencia del oráculo de PC-05** sin cambiar su estado (M-01).

Bloque 2 — Si hay margen antes de la entrega definitiva

- Informar los errores de parseo de la corrida del corpus y la lógica de fallback a GENERAL (M-03).
- Acotar el alcance del TMR de Telegram al tramo de salida (M-04).
- Mencionar el reintento de C3-R3 y su análisis de sensibilidad (M-05).
- Completar el recuento de la §2.5 y extender la recomendación al bloque de identidad (M-06).
- Consignar el caso 352 junto a la cifra de 2 de 18 (M-07).
- Declarar la razón real del tamaño del corpus (M-08).

- Resolver los nueve hallazgos bajos, que son de edición o de informe de datos ya disponibles.

9. Preguntas probables del tribunal

- «¿Hubo alguna otra corrida del corpus además de la del 12/08 a la noche?» Hoy la respuesta no está en el documento (A-02). Es preferible que esté escrita.
- «¿Qué pasa si un cliente escribe su reclamo en inglés, con un apóstrofo?» Según la lectura del nodo, la ejecución falla antes del envío (A-03). Conviene llegar con la respuesta y con la corrección.
- «El panel dice 173 y la Tabla 5.3 dice 174. ¿Cuál es?» A-01. Un tribunal técnico lo ve en la primera lectura del Capítulo 5.
- «¿El 92,7 % se midió sobre el sistema que muestra la Figura 6?» No: sobre la versión de catorce nodos, con el mismo camino de clasificación. El Anexo L lo reconstruye; el Capítulo 4 debería decirlo.
- «¿No es FAQ preguntar si tienen local físico?» Sí, según el propio etiquetado del corpus (M-01).
- «¿Qué hace el sistema si el modelo no devuelve JSON?» Lo registra como GENERAL y responde con un mensaje de error (M-03). Conviene tener el recuento de la corrida del corpus.
- «Entonces, ¿la base de conocimiento no sirve?» Sirve para redactar, no para clasificar, y el diseño factorial mide solo lo segundo. La respuesta está bien dada en la §5.2.4.
- «¿Por qué el factor de 780 ya no es una cota?» Porque los sesgos de sus dos términos operan en sentidos opuestos (§5.4). Conviene sumar el sesgo de expectativa del operador, que la §3.6.2 declara y la §5.4 no repite.
- «¿El asistente le dice al cliente que no es un bot?» En la corrida medida dijo ser una persona, y en la configuración vigente respondió una vez «No soy un bot genérico» (M-06).
- «¿Por qué no fijaron la temperatura?» No se fijó en el nodo, y el trabajo lo declara y lo cuantifica con tres repeticiones. La respuesta está disponible.

10. Dictamen

Dictamen: aprobado — apto para la defensa, con tres observaciones mayores que deben subsanarse en el documento antes de la entrega definitiva.

Puntaje global: **8,2 / 10**

Fundamentación

El trabajo que llega a esta instancia es metodológicamente superior al anterior. Sometió a un diseño controlado la conclusión que más lo favorecía y la corrigió cuando el diseño la desmintió. Reportó un instrumento que no funcionó en lugar de disimularlo. Reclasificó pruebas que antes se daban por aprobadas. Documentó qué versión de su artefacto produjo cada medición. Y cada cifra que publica se reproduce desde los datos crudos de un repositorio público. Varias de esas decisiones corrigen afirmaciones que este tribunal había validado en la instancia anterior, y el tribunal lo reconoce.

No corresponde una calificación mayor porque la auditoría del repositorio mostró que la transparencia del documento es selectiva en tres puntos que el equipo tenía registrados. Una corrida con pérdida silenciosa del 23 % de los mensajes, un defecto de construcción de consultas calificado internamente como de severidad alta y una explicación del tablero incompatible con las vistas aplicadas no son errores de medición: son omisiones de escritura en un trabajo cuya virtud declarada es escribir lo que mide. El Anexo L demuestra que el equipo sabe hacerlo; lo que se pide es que lo haga también con esto.

El resto es de alcance menor: afirmaciones que dicen un poco menos o un poco más que los datos, controles cuyo resultado existe y no se informa, y residuos de nomenclatura.

Sobre el margen que resta

Ejecutado el Bloque 1, este tribunal estima el trabajo entre 8,6 y 8,8. El Bloque 2 lo llevaría a un rango de 8,9 a 9,1, cerca del techo de la categoría para un prototipo de laboratorio con un solo operador en el baseline y sin una evaluación reproducible del contenido de las respuestas.

Cierre

La segunda auditoría cerraba diciendo que el trabajo se defendía solo. Esta vez el tribunal encontró que el trabajo se defiende mejor de lo que aquella auditoría creía —porque corrigió errores que el propio tribunal había dejado pasar— y, a la vez, que el repositorio sabe más que el documento. La distancia entre ambos es corta y es toda de escritura: tres declaraciones y un puñado de precisiones. Un trabajo que publica sus datos para ser refutado tiene que publicar también sus corridas fallidas y sus defectos conocidos. Con eso hecho, la defensa no debería traer sorpresas.